

Modelos de Fundação Genômica para Fragmentômica de *cfDNA*

Projeto de Mestrado em Biologia Computacional e Sistemas

Linha de Pesquisa : Genoma, transcriptoma, proteoma e metaboloma

Instituto Osvaldo Cruz

Frederico Flores

Orientador: Eduardo Krempser da Silva

Modelos de fundação genômica
conseguem extrair padrões
semânticos complexos da
sequencia bruta de cfDNA ?

Aprendizado de máquina profundo, realizado com modelos de fundação genômica, sobre dados brutos de sequenciamento genético raso de *cfDNA*, tem capacidade preditiva similar aos métodos de modelagem estatística referência, com a vantagem de baixo custo computacional e ajuste fino dinâmico.

- Montar um dataset padronizado, com dados WSG de cfDNA de fontes públicas (FinaleDB, EGA, TeifLAB)
- Benchmark diferentes arquiteturas de redes neurais para esta tarefa (AttentionMIL, CLAM, DTFD-MIL, TransMIL)
- Simular ajuste fino em arquitetura de Aprendizado Federado


FASE 1: Engenharia de Dados e Extração de Características

Aquisição e Filtragem de Dados




Fonte: 2.361 amostras de pacientes de arquivos FinaleDB
FinaleDB BED, filtradas por assinaturas ENCODE GRCh38-PLS.

Isolamento da Janela Promotora



Extração de janelas de 1.000 pb de coordenadas do genoma de referência para capturar locais ativos de regulação transcricional.

Extração de Características Multimodal




Combinação da sintaxe latente do Modelo Caduceus com histogramas de 20 partições de densidade de fragmentação do DNA.

FASE 2: Arquitetura e Análise


Construção de Tensor Multimodal

Sintaxe Semântica do DNA




Perfis de Fragmentação

Vetor de 276 dimensões




Concatenação da sintaxe semântica do DNA e dos perfis de fragmentação em um vetor denso de 276 dimensões.

Classificação MIL com Atenção



Implantação de Aprendizado de Instâncias Múltiplas (MIL) com um Mecanismo de Atenção para ponderar regiões genômicas significativas.

Atlas de Acessibilidade da Cromatina



Resultados validados do conjunto de teste cego independente após 30 épocas de treinamento.

- CRISTIANO, Stephen et al. Genome-wide cell-free DNA fragmentation in patients with cancer. *Nature*, v. 570, n. 7761, p. 385-389, 2019.
- SCHIFF, Y. et al. Caduceus: Bi-Directional Equivariant Long-Range DNA Sequence Modeling. In: *International Conference on Machine Learning (ICML)*, 41., 2024, Viena. *Proceedings... Viena: PMLR*, 2024. p. 43632-43673.