

Modelos de Fundação Genômica para Detecção de Sinais Tumoriais em cfDNA por ulpWGS

Linha de Pesquisa : Genoma, transcriptoma, proteoma e metaboloma

é possível diagnosticar câncer através de um simples exame de sangue, com custo acessível para disponibilizado SUS?

Aprendizado de máquina profundo,
realizado com modelos de fundação
genômica, pode desenvolver capacidade
preditiva de alta resolução e precisão
clínica, com baixo custo computacional.

- Catalogar modelos de fundação genômica pré-treinados
- Montar um dataset com o maior volume possível de dados WSG de cfDNA catalogado (câncer X saudável)
- Definir estratégias tratamento dos dados / padronização / regiões alvo
- Testar diferentes arquiteturas de redes neurais
- Comparar resultados com baseline (DELF1)


FASE 1: Engenharia de Dados e Extração de Características

Aquisição e Filtragem de Dados




Fonte: 2.361 amostras de pacientes de arquivos FinaleDB
FinaleDB BED, filtradas por assinaturas ENCODE GRCh38-PLS.

Isolamento da Janela Promotora



Extração de janelas de 1.000 pb de coordenadas do genoma de referência para capturar locais ativos de regulação transcricional.

Extração de Características Multimodal




Combinação da sintaxe latente do Modelo Caduceus com histogramas de 20 partições de densidade de fragmentação do DNA.


FASE 2: Arquitetura e Análise

Construção de Tensor Multimodal


Sintaxe Semântica do DNA



Perfis de Fragmentação




Vetor de 276 dimensões




Concatenação da sintaxe semântica do DNA e dos perfis de fragmentação em um vetor denso de 276 dimensões.

Classificação MIL com Atenção



Implantação de Aprendizado de Instâncias Múltiplas (MIL) com um Mecanismo de Atenção para ponderar regiões genômicas significativas.

Atlas de Acessibilidade da Cromatina



Resultados validados do conjunto de teste cego independente após 30 épocas de treinamento.

- CRISTIANO, Stephen et al. Genome-wide cell-free DNA fragmentation in patients with cancer. *Nature*, v. 570, n. 7761, p. 385-389, 2019.
- SCHIFF, Y. et al. Caduceus: Bi-Directional Equivariant Long-Range DNA Sequence Modeling. In: *International Conference on Machine Learning (ICML)*, 41., 2024, Viena. *Proceedings... Viena: PMLR*, 2024. p. 43632-43673.